

Actividad 2 - Arboles: Resultado ID3 sobre Iris

Alferry

2 de julio de 2026

Punto 2: Arbol de decision ID3 sobre el dataset Iris (discretizado)

1. Metodologia

Se utilizo el dataset Iris discretizado (atributos `sepal1`, `sepalw`, `petall`, `petalw` categorizados en **chico** / **mediano** / **grande**, tomado de la hoja `disc_a1` del archivo `naive-bayes.iris.data.xlsx` provisto por el profesor) para construir un arbol de decision con el algoritmo **ID3** clasico:

- Criterio de particion: **ganancia de informacion** basada en entropia.
- Sin poda (unpruned), como corresponde a ID3 puro.
- Atributos estrictamente categoricos (no maneja continuos, a diferencia de C4.5/J48).
- Las hojas se etiquetan con la clase mayoritaria del subconjunto correspondiente.
- Se implemento desde cero en Python siguiendo el algoritmo original de Quinlan (1986).

2. Atributo raiz seleccionado

El atributo con mayor ganancia de informacion en la raiz fue:

petalw (ancho de petalo), con ganancia de informacion = 1.3187 bits

Esto es consistente con el hecho conocido de que el ancho del petalo es el atributo mas discriminante para separar las tres especies de Iris (en particular, separa perfectamente **Iris-setosa** del resto en la primera particion).

3. Arbol resultante (texto)

```
[petalw] (ganancia=1.3187, n=150)
  petalw = chico:
    -> Iris-setosa (n=50)
  petalw = mediano:
    [petall] (ganancia=0.2361, n=48)
      petall = chico:
        -> Iris-versicolor (n=1)
      petall = mediano:
        -> Iris-versicolor (n=42)
      petall = grande:
        [sepal1] (ganancia=0.4200, n=5)
          sepal1 = chico:
            -> Iris-virginica (n=0)
```

```

    sepall = mediano:
        -> Iris-virginica (n=2)
    sepall = grande:
        [sepalw] (ganancia=0.2516, n=3)
        sepalw = chico:
            -> Iris-versicolor (n=2)
        sepalw = mediano:
            -> Iris-versicolor (n=1)
        sepalw = grande:
            -> Iris-versicolor (n=0)
    petalw = grande:
        [petall] (ganancia=0.1131, n=52)
        petall = chico:
            -> Iris-virginica (n=0)
        petall = mediano:
            [sepalw] (ganancia=0.6667, n=6)
            sepalw = chico:
                -> Iris-virginica (n=2)
            sepalw = mediano:
                -> Iris-versicolor (n=2)
            sepalw = grande:
                -> Iris-versicolor (n=2)
        petall = grande:
            [sepall] (ganancia=0.0154, n=46)
            sepall = chico:
                -> Iris-virginica (n=0)
            sepall = mediano:
                [sepalw] (ganancia=0.0699, n=9)
                sepalw = chico:
                    -> Iris-virginica (n=6)
                sepalw = mediano:
                    -> Iris-virginica (n=2)
                sepalw = grande:
                    -> Iris-virginica (n=1)
            sepall = grande:
                [sepalw] (ganancia=0.0265, n=37)
                sepalw = chico:
                    -> Iris-virginica (n=11)
                sepalw = mediano:
                    -> Iris-virginica (n=19)
                sepalw = grande:
                    -> Iris-virginica (n=7)

```

4. Evaluacion sobre las 150 instancias

El arbol fue evaluado clasificando las 150 instancias del dataset (entrenamiento = prueba, sobre el dataset completo, sin particion holdout ni validacion cruzada).

Exactitud (accuracy): 97.33% (146/150 instancias correctas)

Matriz de confusion (filas = clase predicha, columnas = clase real)

predicho	real	setosa	versicolor	virginica
setosa		50	0	0
versicolor		0	48	2
virginica		0	2	48

Interpretacion

- **Iris-setosa** se clasifica perfectamente (100%): es completamente separable con solo el atributo **petalw**.
- Los unicos errores ocurren entre **Iris-versicolor** y **Iris-virginica** (2 instancias de cada clase mal clasificadas), que son las especies con mayor solapamiento en sus atributos discretizados. Este es un resultado esperado y consistente con la literatura sobre el dataset Iris.

5. Archivo de trabajo

El detalle completo (datos originales, datos discretizados, arbol completo, clasificacion instancia por instancia y matriz de confusion con formulas verificables) se encuentra en el archivo **ID3_Iris_resultado.xlsx** incluido junto a este reporte.